

Predicție liniară

Laborator 12, PSS

Obiectiv

Studiul predicției liniare a semnalelor.

Noțiuni teoretice

Predicția liniară reprezintă estimarea unui eșantion al semnalului $x[n]$ ca o combinație liniară a N eșantioane precedente:

$$x[n] \approx a_1x[n-1] + a_2x[n-2] + \dots + a_Nx[n-N]$$

Semnalele care respectă (aproximativ) o astfel de relație se numesc “autoregresive” (AR). N reprezintă ordinul modelului autoregresiv.

Exerciții

1. Se consideră sistemul descris de ecuația cu diferențe

$$y[n] = 0.8y[n-1] + x[n] + x[n-1],$$

unde $x[n]$ este un proces aleator staționar cu medie 0 și autocorelație $\gamma_{xx}[m] = \left(\frac{1}{2}\right)^{|m|}$

- a. Determinați densitatea spectrală de putere a ieșirii $y[n]$;
 - b. Determinați funcția de autocorelație a ieșirii, $\gamma_{yy}[m]$;
 - c. Determinați varianța σ_y^2 a ieșirii.
2. Predicție liniară pe un semnal liniar

- Generați un semnal liniar crescător (cu pantă constantă), de lungime 200 eșantioane. Folosiți de ex. notația `start:step:stop`
- Modelăm semnalul ca un proces autoregresiv de ordin 10, AR(10). Calculați coeficienții de predicție a_k cu funcția Matlab `lpc()`.
- Pe baza coeficienților de predicție, folosind relația de predicție, preziceți următoarele 200 eșantioane ale semnalului. Afișați întregul semnal rezultat (400 eșantioane)
- Generați același semnal crescător cu lungime 400 eșantioane direct cu formula inițială. Afișați pe aceeași figură semnalul acesta și semnalul precedent (2 x 400 eșantioane).

Ce calitate are porțiunea prezisă, comparativ?

- Discuție:
 - ce ordin autoregresiv are acest model?

3. Predicție liniară pe diverse semnale.

Repetati ex. precedent pentru un semnal de forma:

- Semnal exponențial: $x[n] = (0.9)^n u[n]$. Porniți de la un semnal de lungime 50, și estimați următoarele 50 eșantioane.
- Semnal sinusoidal: $x[n] = 3 \cdot \sin(2 * \pi * f * n) u[n]$, $f = 0.05$. Porniți de la un semnal de lungime 50, și estimați următoarele 50 eșantioane.
- Sinusoidă exponențială: $x[n] = 0.8^n \cdot \sin(2 * \pi * f * n) u[n]$, $f = 0.2$. Lungime 50 + 50
- Semnal de tip zgomot alb gaussian (AWGN, generat cu `randn()`). $x[n] = 0.8^n \cdot \sin(2 * \pi * f * n) u[n]$, $f = 0.2$. Lungime 500 + 100. Apoi lungime 20 + 100.
- Semnal de tip zgomot alb uniform (generat cu `rand()`). $x[n] = 0.8^n \cdot \sin(2 * \pi * f * n) u[n]$, $f = 0.2$. Lungime 500 + 100. Apoi lungime 20 + 100.
- Semnal sinusoidal in zgomot alb: $x[n] = 2 \cdot \sin(2 * \pi * f * n) u[n] + AWGN$, $f = 0.05$. Lungime 100 + 100.

4. Detectia vocii (Voice Activity Detector).

- Încărcați semnalul audio `data_slow.wav` (cu `audioread()`), afișați-l grafic și redați-l audio.
- a. Utilizați funcția `buffer()` pentru a împărți semnalul în ferestre cu lungimea de aproximativ 25ms.

- b. Modelați fiecare segment semnalul ca un proces aleator $AR(12)$, și găsiți coeficienții liniari de predicție pentru fiecare segment cu funcția `lpc()`
 - c. Pentru fiecare segment, calculați energia coeficienților de predicție (suma coeficienților la pătrat). Afișați secvența de valori obținută.
 - d. De pe grafic, alegeți un prag convenabil pentru a diferenția segmentele de voce de cele de pauză.
 - e. Eliminați segmentele din semnal care sunt de pauză, și reuniți segmentele rămase într-un semnal întreg. Ascultați semnalul astfel obținut.
5. Repetați exercițiul anterior, dar adăugând peste semnalul inițial zgomot AWGN. Până la ce nivel de zgomot se obțin rezultate bune?
 6. Incărcați imaginea `lena512.bmp`. Transformați în 0 valorile de pe liniile 20 : 30, coloanele de la 100 la 150.

Refaceți imaginea în felul următor: pentru fiecare linie separat, modelați primele 100 eșantioane cu un proces $AR(10)$, apoi estimați cele 50 valori lipsa care urmează.

Afișați imaginea astfel obținută.

Întrebări finale

1. TBD